



MVP - Data Engineering

Análise do impacto da precipitação pluviométrica na diluição da laje de sal.

Aluno: Vinicius Leonardo Lança

Email: viniciusllanca@gmail.com

GitHub: <https://github.com/viniciuslanca/mvp-dataengineering>

Discord: viniciusleonardolanca_95544

Sprint: Engenharia de Dados (40530010057_20260_01)

Sumário

1. Contexto.....	3
2. Os monitoramentos utilizados	4
2.1 Medição das bacias de evaporação.....	4
2.2 Leitura de pluviômetros.....	5
2.3 Medição da laje de sal	5
3. Estrutura dos dados brutos	6
3.1 MEDICAO_LAJE — 226 linhas, 16 colunas	6
3.2 MEDICAO_BACIAS — 506 linhas, 12 colunas	7
3.3 LEITURA_PLUVIOMETROS — 3.445 linhas, 8 colunas.....	8
3.4 Alinhamento com as perguntas	8
4. Licença e condições de uso dos dados	9
5. Carga dos Dados.....	9
5.1 Origem dos dados e coleta	9
5.2 Ingestão na camada Staging	10
6. Modelagem e Catálogo de Dados	13
6.1 Organização em camadas	13
6.2 Escolha do modelo dimensional na Gold	13
6.3 Tabelas analíticas e visões	14
6.4 Governança	17
6.4.1 Chaves primárias e estrangeiras.....	17
6.4.2 Restrições CHECK.....	18
6.4.3 Linhagem	18
7. Carga e Pipeline	19
7.1 Cinco notebooks, um por etapa	19
7.2 O caminho dos dados	20
7.3 Refazer tudo do zero	20
8. Qualidade dos dados	21
8.1 Como a verificação foi feita.....	21
8.2 Problemas encontrados.....	22
8.3 Cinco descobertas que mudaram o projeto	24
8.4 O que permanece em aberto	25
9. Análise dos resultados	25
9.1 Pergunta 1 — a chuva reduz a espessura da laje?.....	26
9.2 Pergunta 2 - O que importa mais: quanto chove ou quantos dias chove?	28
9.3 Pergunta 3 — 2026 foi um ano atípico?.....	29
10 . Autoavaliação	30

1. Contexto

A produção de sal marinho ocorre em tanques rasos chamados cristalizadores (Figura 1), onde a salmoura evapora e o cloreto de sódio cristaliza, depositando-se no fundo em uma camada compacta conhecida como laje. A espessura dessa laje é a medida física da produção acumulada.



Figura 1

Vento e radiação solar aceleram a evaporação e, com ela, a velocidade de fabricação. A chuva age no sentido oposto e de forma dupla: interrompe a evaporação enquanto ocorre e dissolve parte da laje já formada, revertendo produção que já havia sido contabilizada. É essa segunda perda que raramente é quantificada.

Previsibilidade de produção é importante para qualquer empresa, mas pesa mais no setor salineiro: o sal é uma commodity de baixo valor unitário, em que a margem depende de volume e de eficiência operacional. Sem estimar a perda por chuva, o planejamento de safra trabalha com um erro sistemático para cima.

O objetivo deste trabalho é quantificar o impacto das chuvas na diluição da laje de sal dos cristalizadores. Três perguntas orientam a análise:

1. Qual é a relação quantitativa entre a precipitação acumulada e a variação da espessura da laje?
2. Qual regime de precipitação é mais danoso à produção: chuvas de grande volume concentradas em poucos eventos ou chuvas frequentes de volume reduzido?
3. O período analisado representa um ano de chuva típico, seco ou atípico frente à série histórica da salina?

As duas primeiras perguntas exigem o cruzamento das três fontes de dados. A terceira depende apenas da série pluviométrica e serve para situar o resultado: um efeito medido em um ano atípico tem alcance diferente de um efeito medido em um ano representativo.

2. Os monitoramentos utilizados

O controle produtivo da salina gera diversos registros diários. Três foram selecionados por cobrirem os três elos da cadeia: a energia disponível para evaporar, a água que chega do céu e o resultado depositado no cristalizador.

O recorte temporal da análise cruzada é de janeiro a agosto de 2026. O limite é dado pela medição da laje, cuja série disponível se inicia em janeiro e se encerra em agosto de 2026; como as perguntas 1 e 2 exigem as três fontes simultaneamente, elas ficam restritas a esse intervalo.

A série pluviométrica, porém, é preservada integralmente até a camada Silver, e o recorte é aplicado apenas na camada Gold, onde ocorre o cruzamento. Essa escolha atende à pergunta 3: caracterizar o regime de chuvas de 2026 exige justamente o histórico que as outras duas fontes não possuem.

2.1 Medição das bacias de evaporação

O monitoramento é feito em duas bacias circulares de 1 metro de diâmetro, o que corresponde a uma área de espelho d'água de 0,785 m² cada. Elas operam lado a lado, uma com água doce e outra com salmoura, e são medidas diariamente pelo método de reposição até marca de referência: registra-se o volume, em litros, necessário para restituir o nível original, que corresponde à evaporação do dia, ou o volume retirado, quando a chuva eleva o nível acima da marca. As duas situações são mutuamente exclusivas, de modo que o registro diário é uma única grandeza com sinal.

Como a lâmina evaporada é o volume dividido pela área, a conversão de litros para milímetros depende apenas do diâmetro da bacia. Essa padronização é necessária para que a evaporação seja comparável à precipitação, registrada em milímetros pelos pluviômetros.

Nesse mesmo ponto mede-se diariamente a concentração da salmoura em graus Baumé (°Bé) com densímetro. Medir os dois fluidos lado a lado, sob o mesmo clima e no mesmo dia, é o que permite isolar o efeito da salinidade sobre a taxa de evaporação; sem essa comparação, qualquer diferença observada poderia ser atribuída às condições meteorológicas do período.

Existe na salina um segundo ponto de medição de bacia, que não registra a concentração da salmoura. Como a densidade é indispensável para interpretar a taxa de evaporação medida, esse ponto foi excluído do escopo deste trabalho.



Figura 2 – Exemplo de bacia de evaporação

2.2 Leitura de pluviômetros

Cinco estações distribuídas pela salina (Figura 3), com série histórica iniciada em 2014. As leituras são registradas por evento, e não diariamente, com intervalos que podem se estender por vários dias entre coletas.

É a única das três fontes com profundidade histórica. Por isso a série é carregada por inteiro, e não apenas no recorte da análise cruzada: são os anos anteriores que permitem avaliar se o período estudado foi chuvoso, seco ou típico para a salina.



Figura 3 - Pluviômetro

2.3 Medição da laje de sal

Realizada mensalmente em 25 cristalizadores, que somam 363,6 hectares, com 8 réguas de 1 metro por cristalizador (Figura 4) — o que estabelece 100 cm como limite superior da leitura. A leitura registrada é a altura livre da régua acima da laje: ela diminui à medida que o sal se deposita e aumenta em duas situações: na colheita, quando a camada é removida, e após chuvas que dissolvem parte da crosta. A média das oito réguas é adotada como medida representativa do cristalizador.



Figura 4- Exemplo de régua de leitura

3. Estrutura dos dados brutos

Os três monitoramentos são registrados em formulários eletrônicos do sistema de gestão de processos da empresa. Cada preenchimento gera uma solicitação, e é dela que vêm quatro colunas comuns às três tabelas: PROTOCOLO (identificador da solicitação), SOLICDATA (data e hora do lançamento no sistema), STATUS (situação do fluxo do processo) e UNIDADE (unidade da empresa).

Essa origem tem duas consequências relevantes para o tratamento. A primeira é que uma solicitação pode conter vários dias ou vários pontos de medição, de modo que o protocolo não corresponde a uma linha nem a uma data: é um agrupamento de lançamento. A segunda é que a data do lançamento é distinta da data da medição. Um formulário preenchido em março pode registrar medições de janeiro.

Os dados foram extraídos do sistema em três arquivos Excel, um por monitoramento.

3.1 MEDICAO_LAJE — 226 linhas, 16 colunas

Grão: uma linha por cristalizador e data de medição. Período: 31/01/2026 a 31/08/2026, em 20 datas distintas.

Coluna	Tipo na origem	Descrição e domínio
PROTOCOLO	inteiro	Identificador da solicitação. 11 protocolos distintos
SOLICDATA	texto dd/MM/yyyy HH:mm:ss	Data e hora do lançamento no sistema
STATUS	texto	Situação do fluxo. Valor único: Solicitação Finalizada
UNIDADE	texto	Unidade da empresa. Valor único: RN
DATAMEDICAO	texto dd/MM/yyyy	Data em que a medição foi feita em campo
CRISTALIZADOR	inteiro	Identificador do cristalizador. Domínio: 1 a 25
AREAHECTARES	decimal	Área do cristalizador em hectares. Constante por cristalizador
REGUA_1 REGUA_8	... inteiro	Altura livre da régua acima da laje, em cm. Limite superior 100 (comprimento da régua)

Coluna	Tipo na origem	Descrição e domínio
OBSERVACOES	texto	Campo livre. Preenchido em 4 das 226 linhas, com informação sobre dias de fabricação e colheita

3.2 MEDICAO_BACIAS — 506 linhas, 12 colunas

Grão: uma linha por ponto de medição e dia. Período: 01/01/2026 a 10/09/2026, em 253 datas distintas.

Coluna	Tipo na origem	Descrição e domínio
PROTOCOLO	inteiro	Identificador da solicitação. 232 protocolos distintos
SOLICDATA	texto dd/MM/yyyy HH:mm:ss	Data e hora do lançamento no sistema
STATUS	texto	Situação do fluxo. Dois valores: Solicitação Finalizada e Validar Dados
UNIDADE	texto	Unidade da empresa. Valor único: RN
BACIA	texto	Ponto de medição. Dois valores: BACIA1 e BACIA2
DATAREGISTRO	texto dd/MM/yyyy	Data da leitura
AGUADOCE_COLOCADO	texto	Volume de água doce repostado até a marca, em litros
AGUADOCE_RETIRADO	texto	Volume de água doce retirado por excedente, em litros
SALMOURA_COLOCADO	texto	Volume de salmoura repostado até a marca, em litros
SALMOURA_RETIRADO	texto	Volume de salmoura retirado por excedente, em litros
SALMOURA_DENSIDADE	texto	Concentração da salmoura em graus Baumé (°Bé), decimal com vírgula
OBSERVACOES	vazio	Campo livre, sem nenhum preenchimento

As quatro colunas de volume chegam como texto porque a ausência de valor é representada por hífen (-), e não por célula vazia. Colocado e retirado nunca aparecem preenchidos no mesmo dia: são estados mutuamente exclusivos do mesmo evento.

3.3 LEITURA_PLUVIOMETROS — 3.445 linhas, 8 colunas

Grão: uma linha por estação e data de leitura. Período: 06/01/2014 a 27/07/2026, em 689 datas distintas.

Coluna	Tipo na origem	Descrição e domínio
PROTOCOLO	inteiro	Identificador da solicitação. 684 protocolos distintos
SOLICDATA	texto dd/MM/yyyy HH:mm:ss	Data e hora do lançamento no sistema
STATUS	texto	Situação do fluxo. Valor único: Solicitação Finalizada
UNIDADE	texto	Unidade da empresa. Valor único: RN
ESTACAO	texto	Estação pluviométrica. Contém 6 rótulos distintos para 5 estações físicas , por variação de grafia — tratado na etapa de qualidade
DATAREGISTRO	texto dd/MM/yyyy	Data da leitura
MILIMETROS	texto	Precipitação em milímetros, decimal com vírgula. Ausência representada por hífen
OBSERVACOES	vazio	Campo livre, sem nenhum preenchimento

3.4 Alinhamento com as perguntas

LEITURA_PLUVIOMETROS: Volume de chuva. Atende as perguntas 1, 2 e 3.

MEDICAO_BACIAS: A evaporação e o efeito da salinidade sobre ela. Atende a pergunta 1.

MEDICAO_LAJE: O sal efetivamente depositado. Atende as perguntas 1 e 2.

As três fontes compartilham a data como chave de junção. MEDICAO_LAJE e MEDICAO_BACIAS compartilham ainda a unidade, mas não há campo que associe um pluviômetro a um cristalizador específico, de modo que a precipitação é tratada como condição comum a toda a salina.

4. Licença e condições de uso dos dados

Os dados utilizados neste trabalho são de natureza operacional privada, provenientes do sistema de controle produtivo de uma empresa do setor de extração de sal marinho. Não se trata de base pública nem de dataset sob licença aberta.

Os dados foram descaracterizados antes do uso e são apresentados de forma agregada, sem elementos que identifiquem a organização de origem. As bases brutas não são redistribuídas, e o repositório disponibiliza apenas o código de tratamento e os resultados consolidados.

Os dados não contêm informação pessoal, de modo que não se aplicam as disposições da Lei nº 13.709/2018 (LGPD). As restrições observadas decorrem de confidencialidade comercial.

5. Carga dos Dados

O pipeline foi construído no Databricks, com governança pelo Unity Catalog (Figura 5). O projeto vive no catálogo mvpdataengineer, organizado em quatro schemas — staging, bronze, silver e gold — e dividido em cinco notebooks numerados, um por etapa. Esta seção descreve os dois primeiros: MVP01-Setup, que cria a estrutura, e MVP02-Download, que faz a coleta e a ingestão.




Figura 5 – Unity Catalog

5.1 Origem dos dados e coleta

Os dados foram disponibilizados em três planilhas Excel, publicadas em uma pasta do Google Drive:

Arquivo de origem	Tabela de destino
LEITURA_PLUVIOMETROS.xlsx	staging.leitura_pluviometros
MEDICAO_BACIAS.xlsx	staging.medicao_bacias
MEDICAO_LAJE.xlsx	staging.medicao_laje

A coleta é feita por requisição à Google Drive API. A autenticação usa uma Service Account do Google Cloud criada para o projeto, com escopo somente leitura (drive.readonly). A chave privada, por questão de segurança, não consta do código versionado.

Os arquivos baixados são gravados em um Volume do Unity Catalog (mvpdataengineer.staging.leituras), que garante persistência entre sessões e governança de acesso. O Volume é limpo antes de cada carga, e a execução é interrompida se algum dos três arquivos não for baixado.

5.2 Ingestão na camada Staging

Cada arquivo é lido e materializado como tabela Delta no schema staging, que é uma cópia fiel da origem.

Todas as colunas são gravadas como texto, sem inferência de tipo. A tipagem é responsabilidade da camada Silver, onde está documentada. Pelo mesmo motivo, as duas formas de ausência presentes na origem são preservadas como vieram, célula vazia como NULL, hífen como a string.

Três colunas de rastreabilidade são acrescentadas na chegada e seguem por todas as camadas: data_ingestao, origem e arquivo_origem. Com elas, qualquer linha da Gold pode ser rastreada até o arquivo e a execução que a produziram.

A carga é do tipo full: .mode("overwrite"). Cada execução substitui integralmente o conteúdo das tabelas. O volume pequeno não justifica a implantação de carga incremental.

Buscando arquivos na pasta de origem...

Arquivos na pasta: 3

- MEDICAO_LAJE.xlsx
- LEITURA_PLUVIOMETROS.xlsx
- MEDICAO_BACIAS.xlsx

Baixando 3 arquivo(s)...

100% MEDICAO_LAJE.xlsx
✓ MEDICAO_LAJE.xlsx
100% LEITURA_PLUVIOMETROS.xlsx
✓ LEITURA_PLUVIOMETROS.xlsx
100% MEDICAO_BACIAS.xlsx
✓ MEDICAO_BACIAS.xlsx

Download concluído: 3 arquivo(s).

Table ▾ +

	^A _C arquivo	^A _C caminho	^A _C modificado_em	1.2 tamanho_kb
1	MEDICAO_LAJE.xlsx	/Volumes/mvpdataengineer/staging/leituras/MEDICAO_LAJE.xlsx	2026-09-12T00:58:12.00...	23.12
2	LEITURA_PLUVIOMETROS.xl...	/Volumes/mvpdataengineer/staging/leituras/LEITURA_PLUVIOMETROS.xlsx	2026-09-12T00:48:01.00...	119.02
3	MEDICAO_BACIAS.xlsx	/Volumes/mvpdataengineer/staging/leituras/MEDICAO_BACIAS.xlsx	2026-09-12T00:14:52.00...	36.25

Figura 6 - Ingestão das planilhas em staging

LEITURA_PLUVIOMETROS.xlsx
Linhas lidas: 3445
Colunas de origem : 8
Tabela: mvpdataengineer.staging.leitura_pluviometros
Registros gravados: 3445

MEDICAO_BACIAS.xlsx
Linhas lidas: 506
Colunas de origem : 12
Tabela: mvpdataengineer.staging.medicao_bacias
Registros gravados: 506

MEDICAO_LAJE.xlsx
Linhas lidas: 226
Colunas de origem : 16
Tabela: mvpdataengineer.staging.medicao_laje
Registros gravados: 226

=====

Ingestão concluída.

Table ▾ +

	^A _C arquivo	1 ² ₃ colunas	1 ² ₃ registros	^A _C tabela
1	LEITURA_PLUVIOMETROS.xl...	11	3445	leitura_pluviometr...
2	MEDICAO_BACIAS.xlsx	15	506	medicao_bacias
3	MEDICAO_LAJE.xlsx	19	226	medicao_laje

Figura 7 - Quantidade d eregistros carregados

```
%sql
SELECT * FROM mvpdataengineer.staging.medicao_bacias LIMIT 10;
```

See performance (1) ✓ Checked for improvements

	PROTOCOLO	SOLICDATA	STATUS	UNIDADE	BACIA	DATAREGISTRO	AGUADOCE_COLOCADO	AGUADOCE_RETIRADO
1	280396	02/01/2026 13:08:09	Solicitação Finaliza...	RN	BACIA1	01/01/2026	9	-
2	280396	02/01/2026 13:08:09	Solicitação Finaliza...	RN	BACIA1	02/01/2026	11	-
3	280901	05/01/2026 16:44:33	Solicitação Finaliza...	RN	BACIA1	03/01/2026	14	-
4	280901	05/01/2026 16:44:33	Solicitação Finaliza...	RN	BACIA1	04/01/2026	10	-
5	280901	05/01/2026 16:44:33	Solicitação Finaliza...	RN	BACIA1	05/01/2026	11	-
6	281043	06/01/2026 15:00:08	Validar Dados	RN	BACIA1	06/01/2026	13	null
7	281456	08/01/2026 13:09:54	Solicitação Finaliza...	RN	BACIA1	07/01/2026	15	-
8	281456	08/01/2026 13:09:54	Solicitação Finaliza...	RN	BACIA1	08/01/2026	13	-
9	281768	09/01/2026 15:54:37	Solicitação Finaliza...	RN	BACIA1	09/01/2026	15	-

Figura 8 - Dados medicao_bacias

```
%sql
SELECT * FROM mvpdataengineer.staging.medicao_laje LIMIT 10;
```

See performance (1) ✓ Checked for improvements

	PROTOCOLO	SOLICDATA	STATUS	UNIDADE	DATAMEDICAO	CRISTALIZADOR	AREAHECTARES	REGUA_1	
1	292552	03/03/2026 11:24:53	Solicitação Finaliza...	RN	31/01/2026	01	16.15	88	88
2	292543	03/03/2026 11:18:30	Solicitação Finaliza...	RN	28/02/2026	01	16.15	86	86
3	300223	09/04/2026 11:23:14	Solicitação Finaliza...	RN	31/03/2026	01	16.15	83	83
4	304213	27/04/2026 11:20:29	Solicitação Finaliza...	RN	31/03/2026	01	16.15	83	83
5	306320	07/05/2026 09:35:58	Solicitação Finaliza...	RN	30/04/2026	01	16.15	82	82
6	323656	02/06/2026 10:25:29	Solicitação Finaliza...	RN	25/05/2026	01	16.15	83	83
7	330749	02/07/2026 10:24:03	Solicitação Finaliza...	RN	26/06/2026	01	16.15	80	81
8	338252	03/08/2026 09:38:41	Solicitação Finaliza...	RN	27/07/2026	01	16.15	99	98
9	345518	02/09/2026 10:25:40	Solicitação Finaliza...	RN	31/08/2026	01	16.15	95	95

Figura 9 - Dados medica_laje

```
%sql
SELECT * FROM mvpdataengineer.staging.leitura_pluviometros LIMIT 10;
```

See performance (1) ✓ Checked for improvements

	PROTOCOLO	SOLICDATA	STATUS	UNIDADE	ESTACAO	DATAREGISTRO	MILIMETROS	OBSERVACOES	data
1	190825	23/05/2025 10:53:42	Solicitação Finaliza...	RN	PLUVIOMETRO1	06/01/2014	4,0	null	2026-09
2	190825	23/05/2025 10:53:42	Solicitação Finaliza...	RN	PLUVIOMETRO2	06/01/2014	2,0	null	2026-09
3	190825	23/05/2025 10:53:42	Solicitação Finaliza...	RN	PLUVIOMETRO3	06/01/2014	0,0	null	2026-09
4	190825	23/05/2025 10:53:42	Solicitação Finaliza...	RN	PLUVIOMETRO4.	06/01/2014	0,0	null	2026-09
5	190825	23/05/2025 10:53:42	Solicitação Finaliza...	RN	PLUVIOMETRO5	06/01/2014	0,0	null	2026-09
6	190826	23/05/2025 10:53:43	Solicitação Finaliza...	RN	PLUVIOMETRO1	30/01/2014	5,5	null	2026-09
7	190826	23/05/2025 10:53:43	Solicitação Finaliza...	RN	PLUVIOMETRO2	30/01/2014	5,5	null	2026-09
8	190826	23/05/2025 10:53:43	Solicitação Finaliza...	RN	PLUVIOMETRO3	30/01/2014	6,0	null	2026-09
9	190826	23/05/2025 10:53:43	Solicitação Finaliza...	RN	PLUVIOMETRO4.	30/01/2014	3,0	null	2026-09

Figura 10 - Dados leitura_pluviometros

6. Modelagem e Catálogo de Dados

6.1 Organização em camadas

O catálogo mvpdataengineer contém quatro schemas, um por camada da arquitetura medalhão, com **20 tabelas e 5 visões** no total.

Schema	Tabelas	Responsabilidade	Tipagem
staging	3	Chegada dos arquivos, cópia fiel da origem	Tudo texto
bronze	3	Dado bruto persistido com metadados de ingestão	Tudo texto
silver	3	Dado limpo, tipado e deduplicado, no grão da origem	Tipado
gold	11 + 5 visões	Modelo dimensional e tabelas analíticas	Tipado

As três primeiras camadas preservam a granularidade da origem. A tipagem só é realizada na Silver. Staging e bronze mantêm todas as colunas como texto para que o schema não dependa do conteúdo dos arquivos.

6.2 Escolha do modelo dimensional na Gold

A camada Gold adota esquema estrela: tabelas de fato e dimensões com os atributos descritivos.

A escolha decorre da natureza dos dados. Separar o que varia a cada medição do que é atributo permanente evita repetir a área do cristalizador em cada linha de fato e concentra a manutenção desses atributos em um único lugar.

O esquema snowflake foi descartado por não haver hierarquia a normalizar. Nenhuma dimensão tem sub-atributos que justifiquem quebra em tabelas adicionais.

Além disso, as três fontes não compartilham da mesma granularidade. As bacias são medidas diariamente, os pluviômetros por evento e a laje mensalmente. Agrupa-las em um único fato exigiria agregar ou replicar dados antes da hora, destruindo informação.

Cada fonte tem sua própria tabela de fato. Sobre elas há três tabelas analíticas que materializam cruzamentos e agregações.

Tabela	Tipo	Grão	Linhas
dim_tempo	Dimensão	Um dia	4.748
dim_mes	Dimensão	Um mês	156

Tabela	Tipo	Grão	Linhas
dim_cristalizador	Dimensão	Um cristalizador	25
dim_estacao	Dimensão	Uma estação	5
dim_fluido	Dimensão	Um fluido	2
fato_precipitacao_diaria	Fato	Estação × dia	~3.400
fato_evaporacao_diaria	Fato	Fluido × dia	~490
fato_laje_medicao	Fato	Cristalizador × medição	200
fato_analise_mensal	Fato analítico	Mês	7
fato_chuva_mensal_historico	Fato analítico	Mês do ano	12
fato_chuva_anual	Fato analítico	Ano	13

Os fatos não compartilham a granularidade temporal: três operam no grão dia e três em grãos superiores. Ligar um fato mensal a um calendário diário produziria explosão de cardinalidade, cada linha do fato se casaria com todos os dias do mês.

A solução adotada é uma dimensão-base com a granularidade dia (dim_tempo) e outra com a granularidade mês (dim_mes). A dim_mes é gerada a partir da dim_tempo, e não de uma lista paralela: é isso que garante que nome_mes, trimestre e estacao_chuvosa signifiquem exatamente a mesma coisa nos dois níveis.

6.3 Tabelas analíticas e visões

As oito primeiras tabelas guardam os dados como eles vêm do campo. As três últimas juntam informações de fontes distintas com a adição de alguns cálculos. Elas existem para que o cálculo seja feito uma vez só.

fato_analise_mensal: Agrupa, mês a mês, o crescimento da laje, a chuva e a evaporação. É a tabela que responde as perguntas 1 e 2. Duas decisões estão embutidas nela.

Como a chuva é somada: A laje é medida uma vez por mês, mas não no mesmo dia para todos os cristalizadores: as medições caem entre os dias 25 e 31. Então a chuva de cada cristalizador é somada entre a medição anterior e a atual, e não do dia 1 ao dia 30.

Por que a média dos 25 cristalizadores: Os 25 ficam na mesma salina e recebem a mesma chuva, no mesmo mês, eles variam quase igual, com diferença média de apenas 0,35 cm entre o que mais cresceu e o que menos cresceu. Contá-los como 25 medições independentes seria como perguntar a mesma coisa 25 vezes e apresentar o resultado como 25 análises. A tabela já entrega a média do mês.

fato_chuva_mensal_historico: Compara a chuva de cada mês de 2026 com a média daquele mesmo mês nos doze anos anteriores. Mostra se choveu na época certa, e não apenas se choveu

o bastante. Um ano pode ter o total normal e mesmo assim ter a estação chuvosa deslocada, o que muda tudo para o planejamento de produção.

fato_chuva_anual: Classifica cada ano como seco, típico ou chuvoso. Compara sempre o acumulado de janeiro a julho, porque a série de 2026 termina em julho: confrontar sete meses de 2026 com doze meses dos outros anos faria 2026 parecer seco sem ser.

Cinco visões entregam os dados no formato exato de cada gráfico:

```
vw_grafico_p1;  
vw_grafico_p2;  
vw_grafico_p3_sazonal;  
vw_grafico_p3_anual e;  
vw_grafico_mensal_long.
```

Elas existem porque as métricas mensais têm amplitudes que diferem. O crescimento da laje varia de $-1,6$ a $+3,0$ cm enquanto a chuva vai de 0 a 110 mm. Cada visão traz o valor real e o valor normalizado em escala 0 a 100.




Figura 11 - Unity Catalog (Silver e Gold)

fato_evaporacao_diaria

Description

Evaporação diária medida em bacia pelo método de reposição, por fluido. Medida consolidada com sinal: positivo é reposição (evaporação), negativo é retirada (excedente de chuva). Funciona como indicador climático composto, já que radiação, vento e nebulosidade não são medidos na salina.

Column	Type	Comment
fluido	string	Fluido medido. Chave estrangeira para dim_fluido.
data	date	Data da medição. Chave estrangeira para dim_tempo.
tipo_evento	string	REPOSICAO quando houve reposição até a marca, RETIRADA quando houve remoção de excedente, SEM_LEITURA quando não houve registro.
volume_litros	decimal(7,2)	Medida com sinal em litros: positivo é reposição, negativo é retirada.
lamina_mm	decimal(7,2)	Volume dividido pela área do espelho de água. Padroniza a unidade para comparação direta com a precipitação.
densidade_be	decimal(4,1)	Concentração da salmoura em graus Baumé. Nulo para água doce.
variacao_densidade_be	decimal(4,2)	Variação da densidade em relação ao dia anterior. Queda acentuada indica diluição por chuva.
data_carga_gold	timestamp	

Figura 12 - Comentários da tabela e campos




Figura 13 - Relacionamento fato_evaporacao_diaria

A documentação completa do Catálogo de Dados está disponibilizada, em formato markdown, no notebook **01.Catalogo_de_Dados** no GitHub. Foi exportada usando a seguinte instrução (Figura 14).

```

CAMADAS = ["staging", "bronze", "silver", "gold"]

cols = spark.sql(f"""
SELECT c.table_schema, c.table_name, t.comment AS desc_tabela,
       c.ordinal_position, c.column_name, c.full_data_type,
       c.comment AS desc_coluna
FROM {CATALOGO}.information_schema.columns c
JOIN {CATALOGO}.information_schema.tables t
     ON t.table_schema = c.table_schema AND t.table_name = c.table_name
WHERE c.table_schema IN ({','.join(repr(s) for s in CAMADAS)})
ORDER BY c.table_schema, c.table_name, c.ordinal_position
""").collect()

linhas, tabela_atual = [], None

for r in cols:
    chave = (r.table_schema, r.table_name)
    if chave != tabela_atual:
        tabela_atual = chave
        linhas.append(f"\n#### {r.table_schema}.{r.table_name}\n")
        if r.desc_tabela:
            linhas.append(f"{r.desc_tabela}\n")
        linhas.append("| Coluna | Tipo | Descrição |")
        linhas.append("---|---|---|")
        descricao = (r.desc_coluna or "-").replace("|", "\\|")
        linhas.append(f"| {r.column_name} | {r.full_data_type} | {descricao} |")

markdown = "\n".join(linhas)
print(markdown)

```

Figura 14

6.4 Governança

De forma complementar, além das descrições, três mecanismos do Unity Catalog foram utilizados.

6.4.1 Chaves primárias e estrangeiras

Declaradas como restrições informativas. Documentam o modelo e fazem o Catalog Explorer montar o diagrama de relacionamento automaticamente. Foram definidas 7 chaves primárias e 7 estrangeiras.

```
ddl_chaves = [
# Dimensões
"ALTER TABLE {c}.gold.dim_tempo      ALTER COLUMN data      SET NOT NULL",
"ALTER TABLE {c}.gold.dim_tempo      ADD CONSTRAINT pk_dim_tempo      PRIMARY KEY (data)",
"ALTER TABLE {c}.gold.dim_mes        ALTER COLUMN ano_mes     SET NOT NULL",
"ALTER TABLE {c}.gold.dim_mes        ADD CONSTRAINT pk_dim_mes         PRIMARY KEY (ano_mes)",
"ALTER TABLE {c}.gold.dim_cristalizador ALTER COLUMN cristalizador SET NOT NULL",
"ALTER TABLE {c}.gold.dim_cristalizador ADD CONSTRAINT pk_dim_cristalizador PRIMARY KEY (cristalizador)",
"ALTER TABLE {c}.gold.dim_estacao    ALTER COLUMN estacao     SET NOT NULL",
"ALTER TABLE {c}.gold.dim_estacao    ADD CONSTRAINT pk_dim_estacao    PRIMARY KEY (estacao)",
"ALTER TABLE {c}.gold.dim_fluido     ALTER COLUMN fluido      SET NOT NULL",
"ALTER TABLE {c}.gold.dim_fluido     ADD CONSTRAINT pk_dim_fluido     PRIMARY KEY (fluido)",
# Fatos analíticos
"ALTER TABLE {c}.gold.fato_analise_mensal ALTER COLUMN ano_mes SET NOT NULL",
"ALTER TABLE {c}.gold.fato_analise_mensal ADD CONSTRAINT pk_analise_mensal PRIMARY KEY (ano_mes)",
"ALTER TABLE {c}.gold.fato_chuva_anual   ALTER COLUMN ano      SET NOT NULL",
"ALTER TABLE {c}.gold.fato_chuva_anual   ADD CONSTRAINT pk_chuva_anual   PRIMARY KEY (ano)",
# Estrangeiras
"ALTER TABLE {c}.gold.fato_precipitacao_diaria ADD CONSTRAINT fk_precip_tempo FOREIGN KEY (data) REFERENCES {c}.gold.dim_tempo",
"ALTER TABLE {c}.gold.fato_precipitacao_diaria ADD CONSTRAINT fk_precip_estacao FOREIGN KEY (estacao) REFERENCES {c}.gold.dim_estacao",
"ALTER TABLE {c}.gold.fato_evaporacao_diaria ADD CONSTRAINT fk_evap_tempo FOREIGN KEY (data) REFERENCES {c}.gold.dim_tempo",
"ALTER TABLE {c}.gold.fato_evaporacao_diaria ADD CONSTRAINT fk_evap_fluido FOREIGN KEY (fluido) REFERENCES {c}.gold.dim_fluido",
"ALTER TABLE {c}.gold.fato_laje_medicao ADD CONSTRAINT fk_laje_tempo FOREIGN KEY (data_medicao) REFERENCES {c}.gold.dim_tempo",
"ALTER TABLE {c}.gold.fato_laje_medicao ADD CONSTRAINT fk_laje_crist FOREIGN KEY (cristalizador) REFERENCES {c}.gold.dim_cristalizador",
"ALTER TABLE {c}.gold.fato_analise_mensal ADD CONSTRAINT fk_analise_mes FOREIGN KEY (ano_mes) REFERENCES {c}.gold.dim_mes",
]

for ddl in ddl_chaves:
    sql = ddl.format(c=CATALOGO)
    try:
        spark.sql(sql)
        print(f'✓ {sql.split('CONSTRAINT')[1].split('REFERENCES')[0].strip()} if 'CONSTRAINT' in sql else 'NOT NULL')
    except Exception as e:
        msg = str(e).split("\n")[0]
        print(f'· já existente ou não aplicável: {msg[:90]}")
```

Figura 15 - Definições de PK e FK

6.4.2 Restrições CHECK

Diferente das chaves, CHECK é imposta na gravação. Os domínios de valores levantados no diagnóstico de qualidade viraram teste executável a cada carga:

```
ddl_checks = [
"ALTER TABLE {c}.gold.fato_precipitacao_diaria ADD CONSTRAINT chk_chuva CHECK (milímetros BETWEEN 0 AND 200)",
"ALTER TABLE {c}.gold.fato_evaporacao_diaria ADD CONSTRAINT chk_densidade CHECK (densidade_be IS NULL OR densidade_be BETWEEN 20 AND 30)",
"ALTER TABLE {c}.gold.fato_evaporacao_diaria ADD CONSTRAINT chk_lamina CHECK (lamina_mm BETWEEN -60 AND 60)",
"ALTER TABLE {c}.gold.fato_laje_medicao ADD CONSTRAINT chk_espessura CHECK (espessura_laje_cm BETWEEN 0 AND 50)",
"ALTER TABLE {c}.gold.fato_laje_medicao ADD CONSTRAINT chk_amplitude CHECK (amplitude_reguas_cm BETWEEN 0 AND 10)",
"ALTER TABLE {c}.gold.fato_laje_medicao ADD CONSTRAINT chk_intervalo CHECK (dias_corridos IS NULL OR dias_corridos BETWEEN 20 AND 40)",
"ALTER TABLE {c}.gold.dim_cristalizador ADD CONSTRAINT chk_area CHECK (area_hectares BETWEEN 1 AND 50)",
]

for ddl in ddl_checks:
    sql = ddl.format(c=CATALOGO)
    try:
        spark.sql(sql)
        print(f'✓ {sql.split('CONSTRAINT')[1].split('CHECK')[0].strip()}")
    except Exception as e:
        print(f'· {sql.split('CONSTRAINT')[1].split('CHECK')[0].strip()}: {str(e).split(chr(10))[0][:80]}")
```

Figura 15 - Check


Se uma futura ingestão trouxer densidade fora da faixa física ou régua acima do limite do instrumento, a gravação falha em vez de propagar o erro até a análise.

6.4.3 Linhagem

A linhagem é registrada automaticamente pelo Unity Catalog, que identifica as tabelas de entrada e saída de cada notebook. O caminho de qualquer coluna da Gold pode ser percorrido até o arquivo Excel de origem:

Google Drive (.xlsx) → Volume staging.leituras → staging.* → bronze.* → silver.* → gold.*

Os metadados `arquivo_origem`, `data_ingestao`, `data_carga_bronze`, `data_carga_silver` e `data_carga_gold`, propagados camada a camada, complementam a linhagem estrutural com a rastreabilidade da execução. Qualquer linha pode ser atribuída ao arquivo e à execução que a produziram.



Name	Direction	Type
 <code>vw_grafico_mensal_long</code> mvpdataengineer.gold	↓ Downstream	View
 <code>vw_grafico_p2</code> mvpdataengineer.gold	↓ Downstream	View
 <code>vw_grafico_p1</code> mvpdataengineer.gold	↓ Downstream	View
 <code>fato_laje_medicao</code> mvpdataengineer.gold	↑ Upstream	Table
 <code>fato_precipitacao_diaria</code> mvpdataengineer.gold	↑ Upstream	Table
 <code>fato_evaporacao_diaria</code> mvpdataengineer.gold	↑ Upstream	Table

Figura 16 - Lineage `fato_analise_mensal`

7. Carga e Pipeline

Aqui é demonstrado o caminho completo. As etapas que os dados percorrem desde a planilha até o gráfico, e como esse caminho pode ser refeito quando necessário.

7.1 Cinco notebooks, um por etapa

O trabalho foi dividido em cinco notebooks executados em ordem, em vez de um único notebook fazendo tudo. A organização fica mais clara, porque cada etapa ocupa um arquivo próprio e o histórico de versões mostra exatamente qual parte foi alterada. Também permite refazer só um pedaço. Quando foi preciso corrigir uma regra de limpeza, bastou rodar da etapa de limpeza em diante, sem baixar tudo de novo do Google Drive. Como cada notebook declara de onde lê e onde grava, o Databricks monta sozinho um diagrama mostrando a origem de cada tabela.

Notebook	O que faz
MVP01-Setup	Cria a estrutura vazia onde os dados vão ser armazenados
MVP02-Download	Baixa os arquivos do Google Drive e os coloca na primeira camada
MVP03-Bronze	Guarda os dados crus, com registro de quando chegaram
MVP04-Silver	Verifica a qualidade, limpa e corrige os dados
MVP05-Gold	Organiza tudo no formato que responde às perguntas

7.2 O caminho dos dados

Cada passagem de uma camada para outra é o que se chama de **ETL**. Extrair de um lugar, transformar, e carregar em outro. O pipeline tem cerca de vinte dessas passagens encadeadas.

#	Notebook	De onde lê	Para onde grava	O que faz no caminho
1	MVP02	Google Drive	Pasta de arquivos na nuvem	Baixa as três planilhas
2	MVP02	Pasta de arquivos	3 tabelas na staging	Converte planilha em tabela, sem mexer no conteúdo
3	MVP03	staging	3 tabelas na bronze	Guarda os dados crus e registra data e arquivo de origem
4	MVP04	bronze	3 tabelas na silver	Corrige erros, padroniza formatos e remove duplicatas
5	MVP05	silver	5 tabelas de apoio na gold	Separa os cadastros: cristalizadores, estações, calendário
6	MVP05	silver	3 tabelas de medição na gold	Calcula as variações que a análise precisa
7	MVP05	tabelas da gold	3 tabelas de resultado	Cruza chuva, evaporação e laje
8	MVP05	gold	5 visões	Deixa os dados prontos para virar gráfico

7.3 Refazer tudo do zero

A cada execução, tudo é refeito. As tabelas são apagadas e reescritas por completo, em vez de receber apenas as linhas novas. Duas razões: o volume é pequeno, cerca de 4.200 registros no total, e as planilhas de origem são exportações completas que às vezes trazem correção de um registro antigo e uma carga que só acrescentasse linhas novas perderia essas correções.

Alguns cuidados garantem que rodar de novo funcione sempre:

Nada quebra na segunda vez. Os comandos que criam estruturas verificam antes se elas já existem. E quando uma tabela é regravada, seu formato é substituído por inteiro, não misturado com o anterior.

Erro para o processo em vez de passar batido. Se o download trouxer menos arquivos que o esperado, se uma tabela de origem estiver vazia, ou se a contagem de linhas não bater entre duas camadas, a execução é interrompida com mensagem clara. É melhor falhar na hora do que gerar um resultado incompleto que só seria notado no fim.

8. Qualidade dos dados

8.1 Como a verificação foi feita

A qualidade foi verificada em dois momentos do notebook MVP04-Silver: antes de qualquer tratamento, sobre os dados crus da camada Bronze, e depois, sobre o resultado na Silver. Rodar os mesmos testes nos dois momentos mostra o problema encontrado e a sua resolução no mesmo notebook.

Foram usadas duas ferramentas, que cobrem coisas diferentes.

O perfil estatístico das colunas: Responde para cada campo de cada tabela, quantos valores estão preenchidos, quantos são distintos, quais são os extremos e como os números se distribuem.

Verificações escritas especificamente para estes dados: Cobrem o que o perfil não alcança. O perfil analisa cada coluna isoladamente. Ele não sabe que a mesma medição pode ter sido lançada duas vezes com valores diferentes, que um registro pode ter sido atribuído à bacia errada, ou que uma leitura de 100 significa espessura zero. Foram esses os problemas encontrados, e nenhum deles apareceria num perfil estatístico.

As duas abordagens são complementares. O perfil dá a visão ampla, as verificações próprias encontram o que importa no contexto do processo.

O Databricks oferece o Data Profile, porém esse comando não é suportado em compute serverless, que é o único disponível na edição gratuita usada no projeto. A limitação levou a uma solução para o objetivo do trabalho. Foram escritas funções específicas em pyspark para a verificação dos perfis (MVP04-SILVER).

8.2 Problemas encontrados

Foram identificados dezoito problemas. A tabela resume cada um e onde ele foi tratado.

#	Dimensão	Problema	Onde foi tratado
1	Consistência	Estação registrada com duas grafias (PLUVIOMETRO4. e PLUVIOMETRO4)	Normalização na Silver
2	Consistência	Ausência de valor representada ora por hífen, ora por célula vazia	Ambas convertidas em nulo na Silver
3	Consistência	Números com vírgula decimal, impedindo conversão	Substituição por ponto antes da conversão
4	Consistência	Tipo de coluna variando conforme o conteúdo do arquivo	Staging e Bronze passaram a guardar tudo como texto
5	Unicidade	26 medições de laje lançadas mais de uma vez	Deduplicação na Silver
6	Unicidade	6 leituras de chuva duplicadas com valores diferentes	Deduplicação com critério explícito
7	Unicidade	Numeração do protocolo não acompanha a data da medição	Desempate passou a usar a data do lançamento
8	Acurácia	Registro de uma bacia rotulado com o nome da outra	Correção explícita na Silver
9	Acurácia	Registro com data trocada	Correção explícita na Silver
10	Acurácia	Leitura da régua interpretada como espessura da laje	Conversão 100 – leitura na Silver
11	Acurácia	Leitura de 100 confundida com falha do instrumento	Identificada como cristalizador recém-colhido
12	Completo	Registros ainda não homologados pela operação	Filtro antes de seguir para a Silver
13	Completo	Um dos pontos de medição sem leitura de densidade	Excluído do escopo; mudou o desenho da dimensão
14	Completo	Série de chuva termina antes da última medição de laje	Marcação de cobertura; valores nulos em vez de zero

#	Dimensão	Problema	Onde foi tratado
15	Acurácia	Uma estação pluviométrica subestimando desde 2024	Marcada na dimensão, permitindo análise com e sem
16	Validade	Intervalo entre medições variando de 25 a 35 dias	Medida normalizada por dias corridos
17	Validade	Colheita confundida com efeito de chuva	Marcação de colheita; períodos excluídos da análise
18	Validade	Frequência de chuva indistinguível do esforço de leitura	Medida renomeada e limitação documentada

Como exemplo da verificação de qualidade temos:

Perfil da tabela de medição de bacias evidenciando que há colunas com hífen ao invés de zero ou nula (Figura 17).

	A _C coluna	Σ ₃ linhas	Σ ₃ nulos	Σ ₃ vazios_ou_hifen	1.2 preenchido_pct	Σ ₃ distintos	A _C menor	A _C maior
1	PROTOCOLO	506	0	0	100	232	280396	347437
2	SOLICDATA	506	0	0	100	232	01/02/2026 14:32:39	31/08/2026 13:37:27
3	STATUS	506	0	0	100	2	Solicitação Finalizada	Validar Dados
4	UNIDADE	506	0	0	100	1	RN	RN
5	BACIA	506	0	0	100	2	BACIA1	BACIA2
6	DATAREGISTRO	506	0	0	100	253	01/01/2026	31/08/2026
7	AGUADOCE_COLOCADO	506	16	260	45.5	15	-	9
8	AGUADOCE_RETIRADO	506	32	449	4.9	15	-	9
9	SALMOURA_COLOCADO	506	0	44	91.3	16	-	9
10	SALMOURA_RETIRADO	506	32	432	8.3	15	-	8
11	SALMOURA_DENSIDA...	506	16	237	50	32	-	28,0
12	OBSERVACOES	506	506	0	0	0	null	null
13	data_ingestao	506	0	0	100	1	2026-09-26 21:40:18.4265...	2026-09-26 21:40:18.4265...
14	origem	506	0	0	100	1	google_drive	google_drive
15	arquivo_origem	506	0	0	100	1	MEDICAO_BACIAS.xlsx	MEDICAO_BACIAS.xlsx

Figura 17 - medicao_bacias – Perfil

Análise exploratória onde é identificado que alguns registros indicam que os dados não foram validados (Figura 18).

Σ ₃ PROTOCOLO	A _C SOLICDATA	A _C STATUS	A _C UNIDADE	A _C BACIA	A _C DATAREGISTRO	A _C AGUADOCE_COLOCADO	A _C AGUADOCE_RETIRADO	A _C SALI
1	280396	02/01/2026 13:08:09	Solicitação Finalizada	RN	BACIA1	01/01/2026	9	5
2	280396	02/01/2026 13:08:09	Solicitação Finalizada	RN	BACIA1	02/01/2026	11	6
3	280901	05/01/2026 16:44:33	Solicitação Finalizada	RN	BACIA1	03/01/2026	14	6
4	280901	05/01/2026 16:44:33	Solicitação Finalizada	RN	BACIA1	04/01/2026	10	5
5	280901	05/01/2026 16:44:33	Solicitação Finalizada	RN	BACIA1	05/01/2026	11	5
6	281043	06/01/2026 15:00:08	Validar Dados	RN	BACIA1	06/01/2026	13	7
7	281456	08/01/2026 13:09:54	Solicitação Finalizada	RN	BACIA1	07/01/2026	15	6
8	281456	08/01/2026 13:09:54	Solicitação Finalizada	RN	BACIA1	08/01/2026	13	7
9	281768	09/01/2026 15:54:37	Solicitação Finalizada	RN	BACIA1	09/01/2026	15	6
10	281940	10/01/2026 15:26:15	Solicitação Finalizada	RN	BACIA1	10/01/2026	11	4
11	282198	12/01/2026 14:03:11	Solicitação Finalizada	RN	BACIA1	11/01/2026	15	7
12	282198	12/01/2026 14:03:11	Solicitação Finalizada	RN	BACIA1	12/01/2026	10	4
13	282731	14/01/2026 13:25:27	Solicitação Finalizada	RN	BACIA1	13/01/2026	15	6
14	282731	14/01/2026 13:25:27	Solicitação Finalizada	RN	BACIA1	14/01/2026	10	4

Figura 18 - medicao_bacias - Exploratória

Identificação de erro na nomenclatura do PLUVIOMETRO4 (Figura 19).

	^B _C valor	¹ ₃ ocorrencias
1	PLUVIOMETRO5	689
2	PLUVIOMETRO2	689
3	PLUVIOMETRO1	689
4	PLUVIOMETRO3	689
5	PLUVIOMETRO4.	635
6	PLUVIOMETRO4	54

Figura 19 - Listagem de Pluviômetros

Identificação de duplicidade de registro na leitura dos pluviômetros (Figura 20).

```
# Pluviômetros – chave (estação, data de registro)

dup_pluv = resumo_duplicidade(bronze_pluv, ["ESTACAO", "DATAREGISTRO"], ["MILIMETROS"], "leitura_pluviometros")
display(dup_pluv)

> See performance \(5\)

> dup_pluv: pyspark.sql.connect.dataframe.DataFrame = [ESTACAO: string, DATAREGISTRO: string ... 6 more fields]

leitura_pluviometros
Chave de negócio .....: ['ESTACAO', 'DATAREGISTRO']
Registros na tabela .....: 3445
Chaves distintas .....: 3439
Lançamentos excedentes .....: 6
Chaves com reenvio .....: 0
Chaves com conflito de valor .....: 6
```

Figura 20 - Duplicidade de registros

Evidência de acurácia após o tratamento dos dados (Figura 21).

```
✓ Unicidade de leitura_pluviometros: 0 chave(s) duplicada(s)
✓ Unicidade de medicao_bacias: 0 chave(s) duplicada(s)
✓ Unicidade de medicao_laje: 0 chave(s) duplicada(s)
✓ Estações distintas: 5 → ['PLUVIOMETRO1', 'PLUVIOMETRO2', 'PLUVIOMETRO3', 'PLUVIOMETRO4', 'PLUVIOMETRO5']
✓ densidade fora de 20-30 °Bé: 0 registro(s)
✓ espessura da laje fora de 0-50 cm: 0 registro(s)
✓ espessura incoerente com a leitura: 0 registro(s)
✓ precipitação fora de 0-200 mm: 0 registro(s)
✓ cristalizador fora de 1-25: 0 registro(s)
✓ Colunas descartadas ausentes em leitura_pluviometros: nenhuma residual
✓ Colunas descartadas ausentes em medicao_bacias: nenhuma residual
✓ Colunas descartadas ausentes em medicao_laje: nenhuma residual
✓ Datas convertidas em leitura_pluviometros: 0 nulo(s)
✓ Datas convertidas em medicao_bacias: 0 nulo(s)
✓ Datas convertidas em medicao_laje: 0 nulo(s)
```

Figura 21 - Evidência do tratamento dos dados

Todas as execuções de perfis de dados das tabelas foram exportadas em formato markdown, no notebook **02.Perfil_de_Dados** no GitHub.

8.3 Cinco descobertas que mudaram o projeto

A maioria dos problemas foi resolvido com uma regra de limpeza. Cinco foram diferentes: mudaram o modelo de dados ou o pipeline.

A régua não media o que parecia: O valor anotado em campo é a altura livre acima da laje, não a espessura do sal. Como a régua tem 1 metro, a espessura é o que sobra. Sem essa conta, o número cai justamente quando o sal se acumula, e toda análise sairia com o sinal trocado. A Silver passou a calcular a espessura, que virou a medida principal do modelo.

O que parecia defeito era medição correta: Três medições marcaram 100 nas oito réguas. A primeira leitura foi de falha do instrumento. Com a regra acima, 100 significa espessura zero. Indica que o cristalizador foi recém-colhido.

Um ponto de medição sem densidade: Sem saber a concentração da salmoura, não é possível interpretar a taxa de evaporação. A BACIA2 não tem essa leitura em nenhum dia. O ponto saiu do escopo, e a dimensão que separaria os dois deu lugar a uma dimensão de fluido: água doce e salmoura, que é o que de fato distingue as medições restantes.

A chuva acaba antes da laje: As leituras de pluviômetro vão até 27 de julho; a última medição de laje é 31 de agosto. Tratar agosto como mês sem chuva seria o erro do conjunto, porque é justamente o ponto que mais puxa o resultado. A solução foi deixar a chuva nula, não zero, quando a janela não tem cobertura. A medição das bacias, que segue até setembro, serve de confirmação: nenhum dia de retirada de excedente em 45 dias indica que agosto foi mesmo seco.

A frequência de chuva não é independente: O pluviômetro é lido porque choveu, não em dia fixo. Contar dias de chuva é contar quantas vezes alguém foi ao pluviômetro. Como uma das perguntas compara volume e frequência, a medida foi renomeada para deixar claro que é um mínimo, e a intensidade, volume dividido por dias, passou a ser o indicador, por sofrer menos com esse efeito.

8.4 O que permanece em aberto

Três limitações ficam declaradas. A frequência de chuva não é mensurável, porque o registro depende de alguém ir ao pluviômetro; a conclusão sobre esse regime é conservadora. Chuva e evaporação andam juntas, mês chuvoso é mês nublado, e com sete meses não há dados para separar o efeito de cada uma, então os indicadores devem ser lidos um de cada vez. E um crescimento atípico segue sem explicação: um cristalizador subiu 8,12 cm em fevereiro contra 2,10 cm dos demais, o que pode ter sido recomposição da laje. Confirmar isso depende da operação.

9. Análise dos resultados

Três informações importantes sobre as análises.

A série de chuva termina em 24 de julho. A última data registrada é 27 de julho, mas nela apenas uma das cinco estações foi lida, e sem valor. O registro foi descartado. Agosto, portanto, não aparece em nenhum gráfico de chuva.

A chuva é média sobre a área, não soma de estações. As cinco estações são lidas em conjunto sempre que chove. Quando a chuva é localizada, algumas ficam secas, e elas entram no cálculo como zero. O número apresentado é quanto choveu em média sobre a salina, não quanto caiu no ponto mais molhado.

Algumas curvas estão normalizadas. Chuva é medida em milímetros e a laje em centímetros; no mesmo gráfico em escala real, uma esmaga a outra. Quando o objetivo é comparar o formato das curvas, os valores vão para uma escala de 0 a 100.

9.1 Pergunta 1 — a chuva reduz a espessura da laje?

Sim, e de forma mensurável: cada 10 mm de chuva no mês dissolve cerca de 0,3 cm de laje.

Expressão SQL Executada:

```
%sql
SELECT ano_mes, cristalizadores,
       variacao_media_cm AS crescimento_laje_cm, variacao_desvio_cm, dias_corridos_medio,
       chuva_volume_mm, evaporacao_agua_mm_dia,
       cobertura_pluviometrica_ok, cobertura_bacia_ok
FROM mvpdataengineer.gold.fato_analise_mensal
ORDER BY ano_mes;
```

	Table	Pergunta1	Pergunta1.2	+						
	ano_mes	cristalizadores	crescimento_laje_cm	variacao_desvio_cm	dias_corridos_medio	chuva_volume_mm	evaporacao_agua_mm_dia	cobertura_pluviometrica_ok		
1	2026-02	22	2.506	1.443	28.0	62.8	10.78	true		
2	2026-03	25	2.450	0.157	31.0	35.9	13.23	true		
3	2026-04	24	1.141	0.106	30.0	97.6	6.54	true		
4	2026-05	25	-1.555	0.115	27.5	101.7	4.00	true		
5	2026-06	21	1.911	0.247	30.6	22.0	12.43	true		
6	2026-07	21	2.440	0.339	32.0	11.55	false			
7	2026-08	22	2.440	0.339	32.0	11.55	false			

Figura 22 - Expressão SQL - Pergunta 1

O gráfico abaixo demonstra que os meses com menor concentração de chuvas tem um crescimento da laje de sal. Nos meses chuvosos a laje encolhe, chegando a ficar negativa em maio devido ao volume e acúmulo de chuvas nos meses de abril e maio.




Figura 23 – Chuva mensal e crescimento da laje




Figura 24 – Volume de Chuva x Crescimento da Laje

O gráfico mostra a tendência. Esta consulta calcula a reta que passa pelos pontos, para que os valores citados no texto tenham origem verificável:




Figura 25 - Tendência

O gráfico de dispersão mostra uma tendência clara: quanto mais chuva no mês, menor o crescimento da laje.

O número mais útil para a operação é o de equilíbrio. Perto de 102 mm de chuva no mês, o ganho por evaporação e a perda por dissolução se anulam. Abaixo disso o cristalizador acumula sal, acima, começa a perder. É um limiar concreto para decidir quando antecipar uma colheita.

A ressalva importante: são sete meses de medição. Os 25 cristalizadores recebem a mesma chuva, então não valem como 160 observações independentes. A tendência é consistente e passa no teste estatístico, mas são poucos pontos. A conclusão indica a direção e a ordem de grandeza do efeito. O valor exato precisaria de mais um ou dois anos para se firmar.

9.2 Pergunta 2 - O que importa mais: quanto chove ou quantos dias chove?

O pluviômetro não é lido todo dia. Ele é lido quando chove. À primeira vista isso inviabiliza a pergunta. Contar dias de chuva pareceria o mesmo que contar idas ao pluviômetro, e a frequência não seria uma medida real.

A saída foi transformar isso em uma premissa explícita e testá-la. Há leitura se e somente se choveu? Logo, dia sem leitura é dia sem chuva.

Se a premissa se sustenta, a ausência de registro deixa de ser lacuna e passa a ser informação, e a frequência vira medida válida. Três testes independentes foram aplicados.

Teste	O que verifica	Resultado
Leituras com valor zero	Se alguém vai ao pluviômetro em dia seco	Passou. Nenhuma leitura zerada em 219; o menor valor registrado é 0,6 mm
Distribuição por dia da semana	Se há dias em que chove e ninguém registra	Passou. Sábado é o dia com mais leituras, domingo vem em terceiro; não há vazio de fim de semana
Cruzamento com as bacias	Se as bacias viram chuva que o pluviômetro não viu	Não passou. Em 8 de 24 dias com retirada de excedente nas bacias não há leitura de pluviômetro

O primeiro teste revelou que a leitura é feita em ronda. Quando chove, alguém percorre as cinco estações. Isso vale para os treze anos da série.

O terceiro derrubou a premissa. Retirar água doce de uma bacia de evaporação só se faz para descartar chuva, então 8 dias choveram e não foram registrados. Estão espalhados de janeiro a julho, em todos os dias da semana. É falha recorrente, não uma parada de coleta.

Foi medido o tamanho do problema: o período tem 44 dias de chuva registrados e ao menos 52 reais, uma subestimação mínima de 15%. Mínima porque a bacia só denuncia a chuva forte o bastante para exigir retirada.

Volume e intensidade continuam comparáveis, porque o mesmo desconto atinge os dois. O que fica comprometido é a contagem de dias. Justamente o que a pergunta queria comparar com o volume.




Figura 26 - Abril e Maio: mesma chuva, regimes diferentes

Abril teve 93,5 mm em 14 dias. Maio teve 109,8 mm em 8 dias. Volume parecido, frequência quase o dobro. Assim é possível distinguir as duas coisas. Sem ele, a comparação seria apenas teórica.

Essa pergunta não pode ser respondida de forma precisa com os dados disponíveis.

9.3 Pergunta 3 — 2026 foi um ano atípico?

No total de chuva, não. Na distribuição ao longo do ano, sim. A estação chuvosa se deslocou de março para maio.




Figura 27 - Chuva de 2026 contra o padrão histórico

A barra de março abaixo da linha de mínimo histórico. Esse é o ponto principal do gráfico e de toda a pergunta. Não é um mês abaixo da média, é um mês abaixo de tudo que já se registrou. E a barra de maio quase no dobro da sua média.

Se compararmos o volume de chuvas dos 14 anos, 2026 está no meio exato do conjunto (Figura 28).




Figura 28 - Chuva de janeiro a julho, por ano

No agregado, 2026 é o ano mais comum possível. Não apenas parecido com a média: é o valor do meio, com seis anos mais secos e seis mais chuvosos. Em dias de chuva, também o sétimo de treze.

O desvio de 19% em relação à média sugeriria ano seco, mas a média não serve de referência aqui. Três anos acima de 600 mm a puxam para cima, e a maioria dos anos fica abaixo dela. O gráfico anual mostra ainda dois grupos separados, seis anos entre 211 e 340 mm, seis entre 488 e 687, nada no meio. 2026 fica no topo do grupo inferior.

O gráfico mensal mostra que março é normalmente o mês mais chuvoso, com média de 129,4 mm. Em 2026 entregou 31,7 mm, abaixo do março mais seco já registrado, que era 46,4 mm. Maio fez o inverso, 109,8 mm contra média de 55,6. O pico da estação chuvosa saiu de março e foi para maio, dois meses de atraso, com o mesmo volume total.

Isso importa porque a salina é planejada por calendário. Se a colheita é programada esperando março chuvoso e abril seco, um ano em que a chuva chega em maio pega o cristizador com a laje já formada. A situação de maior perda.

10 . Autoavaliação

Os três objetivos traçados no início foram atingidos, ainda que não todos da mesma maneira. A primeira pergunta, sobre o impacto da chuva na espessura da laje, foi respondida com um número e com um limiar útil para a operação. A terceira, sobre 2026 ter sido ou não um ano atípico, foi respondida e ainda corrigiu a premissa da própria pergunta. O volume de chuva foi o mais comum possível, e o que fugiu do padrão foi o calendário. A segunda ficou incompleta, e considero esse o resultado mais instrutivo do trabalho. Ao tentar comparar volume e frequência de chuva, descobri que a frequência não é mensurável com o

procedimento atual de coleta, porque o pluviômetro só é lido quando chove. Transformei isso em uma premissa explícita e a testei por três caminhos independentes. Um deles reprovou. Poderia ter apresentado um número e seguido adiante, mas aprendi que reconhecer o limite com evidência vale mais do que entregar uma resposta que não se sustenta.

O maior aprendizado foi governança. Trabalho com dados há três anos de forma informal e sempre tratei catálogo, descrição de coluna e registro de decisão como burocracia a fazer depois da entrega, quando sobrasse tempo. Neste MVP eles foram justamente o que sustentou a análise. Quando descobri que a forma de registrar a chuva mudou entre 2025 e 2026, só consegui corrigir sem quebrar a comparação com treze anos de histórico porque cada transformação estava documentada e o valor original tinha sido preservado ao lado do tratado. Em segundo lugar vem o embasamento teórico sobre arquitetura. Eu já separava camadas por intuição, mas não sabia nomear nem justificar o que devia ficar em cada uma e decidia caso a caso. Entender que a Silver cuida do registro individual e a Gold das agregações resolveu isso. Quando apareceu a correção da chuva, tratei o campo em branco na Silver, calcular a média entre as estações era da Gold.